SEBUAH PERJALANAN EKSPERIMEN

Bisakah fine-tuning IndoBERT mengungguli model teks sederhana?

Klasifikasi sentimen ulasan produk berbahasa Indonesia.

DATA PERJALANAN

5.400

ulasan PRDECT-ID
29 kategori produk

TEKS → SENTIMEN

Negatif / positif



Empat pendekatan.
Satu perbandingan yang dapat diperiksa.

CAKUPAN PROYEK

9 run training, termasuk uji awal
dan replikasi; dilanjutkan evaluasi test.

CABANG AWAL / PEMILIHAN 100 ULASAN

Rating sudah menemukan 100/100 negatif.

Batas ukuran tercapai pada batch validasi ini.
Perjalanan berlanjut ke eksperimen klasifikasi.

Satu dataset, tiga peran.

PRDECT-ID · 5.400 ulasan · dua kelas · model menerima teks saja

TRAIN

3.236

Belajar bobot,
TF-IDF, dan kosakata.

VALIDASI

1.081

Membandingkan run
dan memilih checkpoint.

TEST

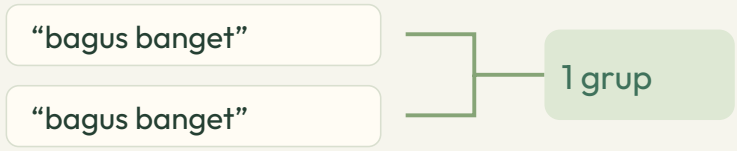
1.083

Evaluasi akhir setelah
keputusan dikunci.

02

TEKS SAMA, KELOMPOK SAMA

CONTOH PENGELOMPOKAN



0 kelompok teks melintasi split.

Salinan teks setelah normalisasi ditempatkan bersama.
Split tetap memakai seed 42.

Pengelompokan ini belum mencakup seluruh parafrasa.

Apakah tambahan training cukup?

E00 → E01 → E02 v1 / v2 · macro-F1 pada 1.081 ulasan validasi yang sama

03

E02 / UBAH ANGGARAN EPOCH

5 epoch

0,8895

118 kesalahan

→

15 epoch

0,9309

74 kesalahan

PEMBANDING E00 / TF-IDF + LOGISTIC REGRESSION

0,9334 · baseline masih lebih tinggi.

Training dimulai ulang dengan seed yang sama; hanya jumlah epoch berubah. Hasil membaik, lalu eksplorasi berlanjut ke IndoBERT.

E02: embedding 64 → mean pooling → linear. E01: uji awal PyTorch lulus.

Sumber: review E00 · E01 · E02_neural_v2.md | E01 memakai subset; skornya tidak masuk perbandingan penuh.

Dua resep dari pretrained yang sama.

E04 frozen dan E05 fine-tuning dimulai terpisah dari IndoBERT asli.

PRETRAINED ASLI

IndoBERT base

04

E04 / ENCODER FROZEN

0,9505

Macro-F1 validasi · 1.538 parameter dilatih

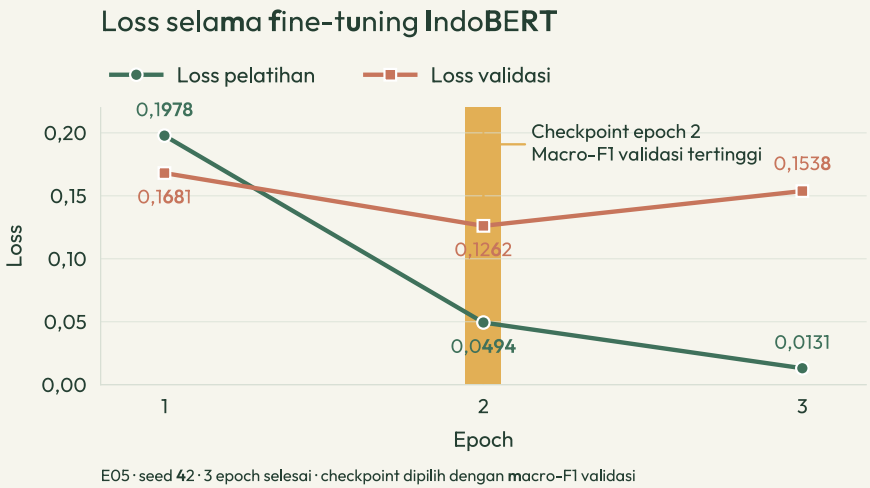
Pembanding tersimpan untuk test

E05 / FULL FINE-TUNING

0,9748

Macro-F1 validasi · 124,4 juta parameter dilatih

E05 / KURVA TRAINING



E05 · seed 42 · 3 epoch selesai · checkpoint dipilih dengan macro-F1 validasi

F1 validasi tertinggi ada pada epoch 2.
Epoch 3: train loss turun, validation loss naik.

05

SIMPAN CHECKPOINT EPOCH 2

POS PERSIAPAN / E03 LULUS

Uji GPU & artefak pada subset 128 train / 64 validasi.

Sumber: review E03 · E04 · E05 · MODEL_CARD.md | Skor: validasi. Resep juga berbeda learning rate dan dropout.

Ulangi resepnya. Amati variasinya.

E05 / E06 / E07 · hanya seed training berubah · split dan resep tetap

E05 / SEED 42

0,9748

Macro-F1 validasi
Checkpoint epoch 2

E06 / SEED 43

0,9739

Macro-F1 validasi
Checkpoint epoch 2

E07 / SEED 44

0,9711

Macro-F1 validasi
Checkpoint epoch 3

06

ULANGI, TANPA MEMILIH ULANG SEED

RATA-RATA TIGA RUN

0,9733 ± 0,0019

SD sampel · n = 3 · satu split tetap

E05 tetap referensi.

Ditetapkan sebelum replikasi.
Bobot dan aturan dikunci sebelum test.

Sumber: RENCANA_REPLIKASI.md · replication_results_v1.md · RENCANA_EVALUASI_AKHIR.md

Sekarang, buka hasil test.

E08 · 1.083 ulasan yang sama · empat model tersimpan · tanpa training baru

07

0,9824

MACRO-F1 TEST / E05

54 → 19

KESALAHAN / E00 → E05

MODEL	MACRO-F1	AKURASI	PRECISION –	RECALL –	SALAH
E00 · TF-IDF	0,9499	95,01%	92,89%	97,86%	54
E02 v2 · neural	0,9464	94,64%	94,36%	95,37%	58
E04 · frozen	0,9528	95,29%	94,27%	96,79%	51
E05 · fine-tuning	0,9824	98,25%	98,05%	98,57%	19

+3,25 poin persentase macro-F1

E05 vs E00 · interval 95%: +1,94 hingga +4,63 poin persentase.
2.000 bootstrap berpasangan pada grup teks; berlaku untuk split dan model ini.

Sumber: E08_final_test_v1.md · MODEL_CARD.md | Precision / recall: kelas negatif. Angka tabel dibulatkan.

Buka kesalahan. Telusuri buktinya.

Prediksi yang keliru tetap menjadi bagian dari hasil proyek.

CONFUSION MATRIX E05 / TEST

	PREDIKSI Negatif	Positif
Acuan negatif	553	8
Acuan positif	11	511

8 negatif terlewat.
11 positif ditandai negatif.

“ini bukan kertas origami tapi post it”

Acuan: negatif / prediksi: positif

08

BUKA KESALAHAN

09

TELUSURI BUKTI

01 **Data & artefak cocok**

ID, teks, label, grup, kode, dan identitas model diperiksa.

02 **Perhitungan diulang**

Metrik dan interval bootstrap dihitung kembali dari CSV prediksi.

03 **Prediksi direproduksi**

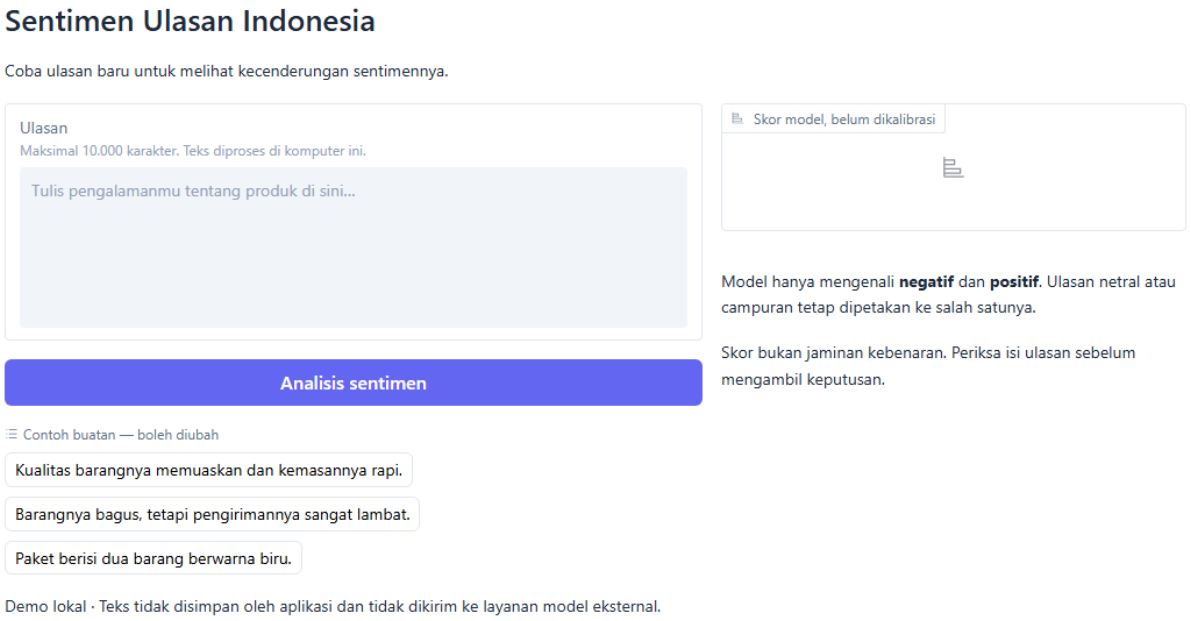
Model E05 offline menghasilkan 1.081 label validasi yang sama.

Sumber: E08_final_test_v1.md · E08_final_test_v1_verification.json · review E05

Sampai pada model yang bisa dicoba.

E05 berjalan pada CPU laptop dan menerima ulasan baru melalui browser.

TEKS → TOKENIZER → CLASSIFIER → SENTIMEN



BATAS PENGGUNAAN

Dua kelas

Negatif atau positif; tidak ada kelas netral.

128 token

Teks panjang dipotong sebelum diproses model.

Skor softmax

Belum dikalibrasi; skor tinggi dapat tetap salah.

Berikutnya: uji data baru, kalibrasi, dan kebutuhan pengguna.

Notebook · bobot · CSV prediksi · laporan audit · demo

10

DEMO LOKAL

FINISH ✓

Generalisasi ke domain baru dan manfaat operasional belum dibuktikan.

Sumber: demo/README.md · MODEL_CARD.md | Tangkapan layar demo lokal asli; bukan prediksi sintetis.